

二阶平衡车强化学习控制实验报告

基于共享仿真环境的控制方法比较

课程项目	强化学习课程实验
实验对象	二阶平衡车
比较方法	Linear PPO、MLP PPO、NAF、SAC
报告作者	曾凡硕
完成日期	2026 年 6 月 18 日

摘 要

本文研究二阶平衡车在仿真环境中的强化学习控制。该系统包含车身和上层摆杆两个开环不稳定的姿态自由度。控制器根据轮角、轮速、车身姿态和摆杆姿态输出连续控制量，使小车在受到扰动后恢复直立，并在匀速任务中跟踪给定轮速。考虑到随机策略直接用于真实小车可能造成频繁摔倒，实验先在统一的 Gymnasium 环境中完成训练与评估，再比较 Linear PPO、MLP PPO、NAF 和 SAC 四种方法。本文所有定量结果和可视化过程均来自仿真实验，真实小车测试留作后续验证。

在小角度线性动力学模型下，Linear PPO 的综合表现最好。该方法在原地平衡和匀速跟踪任务中均达到 **hard** 难度的 100% 成功率，训练过程中也能持续保持稳定。NAF 和 SAC 保存的最优模型同样取得 100% 成功率，但周期评估表明，后续离策略更新使当前策略明显退化，最终结果主要依赖热启动阶段保存的检查点。MLP PPO 在原地平衡任务中的成功率为 90%，在匀速任务中未通过 **easy** 难度。实验数据表明，增加策略网络的非线性容量未在当前模型中带来收益。

报告进一步比较了各方法的课程训练过程、动态响应、训练耗时和部署开销，并结合失败轨迹分析了目标速度未进入观测、离策略训练偏离初始稳定控制器以及仿真模型理想化等问题。在现有实验条件下，Linear PPO 更适合作为真实小车测试的初始方案。后续工作需要补充系统辨识、目标速度条件化、残差策略和动力学随机化实验。

关键词：二阶平衡车，强化学习，PPO，NAF，SAC，连续控制

目 录

摘要	I
1 系统建模与实验任务	1
1.1 控制对象与任务特点	1
1.2 状态、动作与动力学模型	1
1.3 实验任务与奖励函数	2
2 控制方法	3
2.1 Linear PPO	3
2.2 MLP PPO	4
2.3 NAF	4
2.4 SAC	4
2.5 方法与动力学模型的匹配关系	5
3 实验设置	5
4 实验结果与分析	8
4.1 最终评估结果	8
4.2 课程训练过程	9
4.3 原地平衡动态响应	10
4.4 匀速跟踪动态响应	12
4.5 训练与部署开销	13
4.6 动作尺度的影响	14
4.7 方法比较小结	14
5 结果讨论	15
6 现有问题及改进方案	15
6.1 随机探索产生的有效轨迹较少	15
6.2 匀速任务缺少目标速度输入	16
6.3 离策略更新偏离初始稳定控制器	16
6.4 动作尺度与固件接口需要统一	16
6.5 仿真模型对真实系统的覆盖有限	16
7 后续实验安排	17
8 结论	17

1 系统建模与实验任务

1.1 控制对象与任务特点

二阶平衡车由轮式底盘、车身和上层摆杆构成。车身与摆杆在直立点附近均处于开环不稳定状态，姿态发生偏移后会在重力作用下继续增大。控制器需要及时调整车轮运动，使底盘移动产生的惯性作用抵消姿态偏差。

该任务的状态和动作均为连续量。轮子运动会改变车身姿态，车身运动又会影响上层摆杆，因此各状态变量之间存在较强耦合。真实小车的容错时间较短，控制方向或幅值不合适时，系统可能在很短时间内越过安全姿态范围。基于这些特点，训练过程既要保证动作具有足够的调节精度，也要尽量减少无效的随机探索。

1.2 状态、动作与动力学模型

实验使用 `TwoStageBalanceEnv` 作为共享仿真环境。策略接收以下 8 维状态：

```
theta_l, theta_r, theta_l_dot, theta_r_dot,
body_angle, body_rate, pole_angle, pole_rate
```

各状态量的含义如下：

theta_l, theta_r 左右轮角度。

theta_l_dot, theta_r_dot 左右轮角速度。

body_angle, body_rate 车身角度和角速度。

pole_angle, pole_rate 上层摆杆角度和角速度。

策略输出一维归一化动作

$$a_t \in [-1, 1].$$

环境将该动作映射为左右轮同向控制量

$$u_t = \begin{bmatrix} u_l \\ u_r \end{bmatrix} = \begin{bmatrix} a_t u_{\max} \\ a_t u_{\max} \end{bmatrix}, \quad u_{\max} = 8000 \text{ rad/s}^2.$$

本实验只研究前后方向的平衡控制，因此左右轮采用相同控制量。若允许左右轮差速，还需要同时处理横向位移和航向变化，任务范围会明显扩大。

仿真环境采用离散线性状态空间模型

$$x_{t+1} = Gx_t + Hu_t,$$

其中, $x_t \in \mathbb{R}^8$ 为系统状态, $u_t \in \mathbb{R}^2$ 为左右轮控制量。连续模型依据车轮半径、车身质量、摆杆质量、几何尺寸、转动惯量和重力参数建立, 再通过零阶保持方法离散化。表 1 给出了本实验使用的主要物理参数。

表 1 仿真模型的主要物理参数

参数	数值
车轮半径	0.0335 m
车身质量	0.9 kg
摆杆质量	0.1 kg
车身长度	0.126 m
摆杆长度	0.390 m
重力加速度	9.8 m/s ²
控制周期	0.01 s

1.3 实验任务与奖励函数

实验设置原地平衡和匀速跟踪两个任务。原地平衡要求车身和摆杆保持直立, 同时限制轮子位置漂移和动作抖动。匀速跟踪要求系统在维持姿态稳定的条件下, 使左右轮平均角速度接近 2.0 rad/s。两个任务的具体目标见表 2。

表 2 实验任务及评价内容

任务	控制目标	主要评价内容
balance	原地保持车身和摆杆直立	姿态稳定性、轮子漂移和动作平滑性
velocity	保持直立并跟踪平均轮速 2.0 rad/s	姿态稳定性、速度误差和加速过程

奖励函数同时考虑姿态、角速度、轮速、位置漂移、动作幅值、动作变化率和危险姿态, 其简化形式为

$$r_t = r_{\text{alive}} + r_{\text{upright}} + r_{\text{rate}} + r_{\text{speed}} \\ - C_{\text{angle}} - C_{\text{wheel}} - C_{\text{action}} - C_{\text{smooth}} - C_{\text{danger}}.$$

若奖励函数只惩罚姿态误差, 策略可能通过持续移动底盘维持短时直立, 造成明显的位置漂移。若速度项权重过大, 策略又可能使用过强的加速动作, 进而破坏车身

和摆杆的稳定。因此奖励函数需要同时约束姿态和轮子运动。

Shared simulation and online reinforcement-learning loop




图 1 共享仿真环境与强化学习控制闭环

2 控制方法

二阶平衡车采用连续动作控制。若使用 DQN 或表格 Q-learning，需要先对动作进行离散化。动作档位较少时难以实现细致调节，档位较多时又会增加价值估计难度。基于这一考虑，实验选择 PPO、NAF 和 SAC，并分别考察线性策略与多层感知机策略在 PPO 中的表现。

2.1 Linear PPO

PPO 通过限制新旧策略之间的更新幅度提高训练稳定性，其截断目标函数为

$$L^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(\rho_t(\theta) \hat{A}_t, \text{clip}(\rho_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right],$$

其中， $\rho_t(\theta)$ 为新旧策略概率比， $\hat{A}_t$ 为优势估计。PPO 的策略更新较为保守，适合作为连续控制基线。其局限在于只使用当前策略采集的数据，样本不能像离策略方法那样反复利用。

Linear PPO 的 actor 不含隐藏层，结构为

8-D state -> 1-D normalized action

小角度模型采用线性动力学，LQR 控制器也具有线性反馈形式

$$u = -Kx.$$

因此可以将 LQR 权重直接写入线性 actor，使策略从可稳定系统的反馈律开始训练。该结构参数少，推理过程简单，也便于导出到嵌入式平台。实际小车可能存在摩擦、死区、饱和和时延，单一线性反馈在这些情况下的表达能力有限。

2.2 MLP PPO

MLP PPO 使用带两层隐藏层的非线性 actor

8 -> 32 -> 16 -> 1

引入非线性网络主要是为了覆盖标称线性模型未描述的动力学因素，例如电机死区、传感器噪声、电池电压变化和速度环滞后。该网络先通过 LQR 状态动作数据进行行为克隆，再进入 PPO 训练。

与线性 actor 相比，MLP actor 只能近似 LQR 反馈，不能直接得到完全一致的初始控制律。网络参数增多后，未充分采样区域的输出也更难约束。匀速任务还存在一个额外问题，目标轮速没有作为输入提供给策略，网络只能在固定目标下从训练数据中形成隐式控制关系。

2.3 NAF

NAF 将连续动作价值函数写成二次优势形式

$$Q(s, a) = V(s) - \frac{1}{2}(a - \mu(s))^T P(s)(a - \mu(s)).$$

当 $P(s)$ 为正定矩阵时，给定状态下的最大价值动作为 $\mu(s)$ ，从而避免在连续动作空间中数值求解 $\arg \max_a Q(s, a)$ 。NAF 使用经验回放，可以重复利用历史交互数据，但策略质量依赖 Q 函数估计。当经验回放中的状态分布与当前策略差异较大时，价值误差可能传递到动作均值网络。

实验中的 $\mu(s)$ 采用线性结构，价值相关网络使用小型 MLP。训练开始前使用 LQR 轨迹填充经验回放池，使早期批次包含稳定控制数据。

2.4 SAC

SAC 是最大熵离策略 actor-critic 方法，其优化目标包含奖励与策略熵

$$J(\pi) = \sum_t \mathbb{E}_{(s_t, a_t) \sim \rho_\pi} [r(s_t, a_t) + \alpha \mathcal{H}(\pi(\cdot | s_t))].$$

熵项有助于探索连续动作空间，经验回放则提高了数据利用率。对于倒立平衡系统，过多探索也可能使已有稳定策略离开安全区域。当 critic 尚未形成准确估计时，actor 更新容易受到价值误差影响。

本实验采用线性 actor 均值、较小的初始标准差和 LQR 热启动。该设置用于降低训练初期的动作扰动，同时保留 SAC 的离策略更新机制。

2.5 方法与动力学模型的匹配关系

标称仿真模型在直立点附近近似线性，LQR 能够给出与该模型匹配的反馈律。Linear PPO 可以完整继承这一初始反馈，因此预期具有较稳定的训练过程。MLP PPO 具有更大的函数容量，但当前环境中的非线性因素较少，额外参数未必能够带来改进。NAF 和 SAC 可以重复利用样本，其训练效果取决于价值估计能否在更新过程中保持初始控制器的稳定性。

3 实验设置

四种方法使用相同的动力学模型、动作尺度和成功判据。训练从 **easy** 难度开始，周期性评估当前策略。成功率达到设定阈值后，环境依次提升到 **medium** 和 **hard**。最终评估包含 20 个回合，每个回合最多运行 1000 步，对应 10 s 仿真时间。

表 3 通用实验设置

项目	设置
随机种子	11
控制周期	0.01 s
动作上限	8000 rad/s ²
课程难度	easy → medium → hard
最终评估回合数	20
单回合最大步数	1000
成功判据	回合运行至上限且状态满足安全阈值

除日志指标外，实验还保留了网页端仿真测试界面，用于检查策略在闭环运行时的姿态和位移变化。图 2 为原地平衡测试画面，车体在扰动后保持在零点附近，摆杆基本维持直立。图 3 为匀速运动测试画面，车体在保持姿态稳定的同时沿水平方向前进。可视化结果不作为单独评分指标，但能帮助核对控制方向、动作尺度和轨迹形态是否与数值评估一致。

各方法的训练配置见表 4。

实验从最终性能、训练过程、动态响应和计算开销四个方面进行比较。表 5 汇总了主要指标。报告中的方法优劣均限定在本实验设置和评估流程内，不涉及全局最优性证明。




图 2 原地平衡任务的仿真测试画面




图 3 匀速运动任务的仿真测试画面

表 4 各方法的主要训练配置

方法	策略结构	训练步数	主要训练设置
Linear PPO	线性 $8 \rightarrow 1$	200,000	LQR 精确初始化、PPO 截断更新、课程训练
MLP PPO	$8 \rightarrow 32 \rightarrow 16 \rightarrow 1$	600,000	LQR 行为克隆、行为约束、课程训练
NAF	线性 $\mu(s)$, Q 网络 $128 \rightarrow 64$	120,000	经验回放、目标网络、LQR 数据预填充
SAC	线性 actor 均值	200,000	经验回放、最大熵目标、LQR 热启动、最优检查点保存

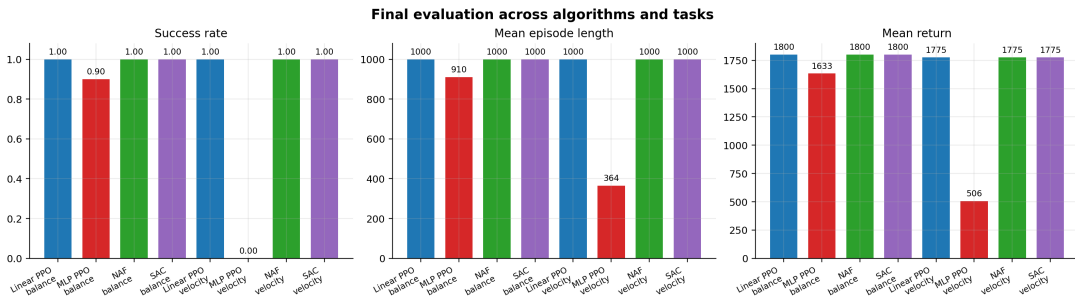


图 4 各方法最终评估指标

表 5 实验评价指标

类别	指标	用途
最终性能	成功率、平均回报、平均回合长度、最终难度	评价策略能否完成控制任务
训练过程	课程晋级步数、周期评估成功率、不同难度下的稳定性	观察训练是否持续改进以及是否发生退化
动态响应	姿态峰值、调节时间、速度误差、失败时间	分析控制过程的超调、收敛和失稳情况
计算开销	训练步数、运行时间、模型大小、actor 参数量	比较训练成本与部署成本

4 实验结果与分析

4.1 最终评估结果




图5 最终评估回合的结果分布

表6 最终评估结果

算法	任务	难度	成功率	平均长度	平均回报
Linear PPO	balance	hard	1.00	1000.0	1799.70
MLP PPO	balance	hard	0.90	910.0	1633.42
NAF	balance	hard	1.00	1000.0	1799.70
SAC	balance	hard	1.00	1000.0	1799.71
Linear PPO	velocity	hard	1.00	1000.0	1775.22
MLP PPO	velocity	easy	0.00	364.2	505.63
NAF	velocity	hard	1.00	1000.0	1775.22
SAC	velocity	hard	1.00	1000.0	1775.27

Linear PPO、NAF 和 SAC 保存的最终模型在两个任务中均达到 **hard** 难度的 100% 成功率，平均回合长度为 1000 步。三种方法在原地平衡任务中的平均回报约为 1799.7，在匀速任务中的平均回报约为 1775.2。匀速任务还包含速度误差和加速动作代价，因此回报低于原地平衡任务。

MLP PPO 在原地平衡任务中的成功率为 0.90，平均回合长度为 910 步，平均回报为 1633.42。多数回合能够保持直立，但仍有部分初始状态导致提前终止。该方法在匀速任务中只完成了 **easy** 难度评估，成功率为 0，平均回合长度为 364.2 步，未形成可靠的速度跟踪控制。

从失败类型看，MLP PPO 在原地平衡任务中的失败主要由车身向外倾倒引起，表明其反馈在部分较大扰动状态下不足。匀速任务中的失败还包括摆杆外倒和轮速误差过大。策略在提高轮速时使用了更强动作，姿态稳定性随之下降。该结果表明，匀速

任务对速度控制和姿态控制的协调要求高于原地平衡任务。

最终评估结果中，线性策略已经能够覆盖当前标称模型的大部分状态范围。NAF 和 SAC 的保存模型与 Linear PPO 表现接近，但仅凭最终检查点还不能判断其训练过程是否稳定，因此需要结合周期评估曲线进一步分析。

4.2 课程训练过程




图 6 各方法课程训练过程中的周期评估结果

表 7 课程训练过程统计

方法	任务	评估次数	首次 hard 评估	hard 成功率范围	周期平均成功率	最后一次当前策略评估
Linear PPO	balance	10	60k	1.00–1.00	1.00	hard / 1.00
MLP PPO	balance	30	60k	0.55–1.00	0.83	hard / 0.85
NAF	balance	6	未进入	–	0.17	medium / 0.00
SAC	balance	10	未进入	–	0.00	easy / 0.00
Linear PPO	velocity	10	60k	1.00–1.00	1.00	hard / 1.00
MLP PPO	velocity	30	未进入	–	0.00	easy / 0.00
NAF	velocity	6	未进入	–	0.00	easy / 0.00
SAC	velocity	10	未进入	–	0.00	easy / 0.00

Linear PPO 在两个任务中均于 20k 步通过 **easy**，40k 步通过 **medium**，60k 步开始接受 **hard** 难度评估。此后各次评估的成功率都保持为 1.00。LQR 初始化提供了有效的初始反馈，PPO 更新没有破坏该控制规律。

MLP PPO 在原地平衡任务中同样于 60k 步进入 **hard**，但成功率在 0.55 至 1.00 之间波动。训练至 540k 步时曾达到 1.00，最后一次评估又下降到 0.85。该曲线反映出非线性策略对更新较为敏感，性能没有随训练步数稳定提高。匀速任务的 30 次评估始终停留在 **easy**，即使训练步数达到 600k，也没有通过当前难度。

NAF 和 SAC 的周期评估与最终结果存在明显差异。两种方法在热启动阶段均保存了成功率较高的模型，后续离策略更新却使当前策略退化。NAF 在原地平衡任务中于 20k 步仍可通过 **easy**，到 40k 步时已无法通过 **medium**。SAC 在两个任务中的周期评估基本停留在 **easy**，成功率为 0。训练结束时程序重新载入最优检查点，因而最终评估仍达到 100%。




图 7 两种 PPO 策略的课程评估曲线

从训练过程看，Linear PPO 的稳定性明显高于其余方法。MLP PPO 在原地平衡任务中可以进入高难度，但不同检查点之间差异较大。NAF 和 SAC 当前配置下依赖最优检查点保护，训练后期策略本身没有保持热启动阶段的性能。

4.3 原地平衡动态响应

最终成功率不能反映超调和调节时间。为比较控制过程，实验固定以下初始状态并执行确定性测试：

```
body_angle = +3 deg
pole_angle = -2 deg
其他状态 = 0
```

测试记录车身角、摆杆角、平均轮速和动作输出。

四种方法在该初始状态下均完成了 10 秒测试。Linear PPO、NAF 和 SAC 的响应




图 8 原地平衡任务的单回合动态响应

曲线基本重合，车身角在约 0.71 秒后进入 $\pm 0.5^\circ$ 范围，摆杆角在约 0.72 秒后进入相同范围。三种方法的动作 RMS 约为 33 rad/s^2 ，远低于动作上限，稳定后只需要较小控制量。

MLP PPO 的调节时间与线性策略接近，轮速 RMS 略高，稳态阶段存在更明显的小幅波动。该固定初始状态没有触发失败，说明 MLP PPO 具备基本平衡能力。其 90% 的最终成功率表明，主要问题出现在稳定范围和较大扰动状态，而非基本平衡能力。

4.4 匀速跟踪动态响应




图 9 匀速跟踪任务的单回合动态响应

表 8 匀速跟踪任务动态指标

方法	持续时间	终止原因	最大车身角	最大摆杆角	速度 RMSE	进入目标带时间	动作 RMS
Linear PPO	10.00 s	无	5.25°	2.00°	1.071 rad/s	0.56 s	40.8 rad/s^2
MLP PPO	4.32 s	pole_falling_outward	12.38°	36.65°	5.218 rad/s	未进入	77.8 rad/s^2
NAF	10.00 s	无	5.25°	2.00°	1.071 rad/s	0.56 s	40.8 rad/s^2
SAC	10.00 s	无	5.24°	2.00°	1.070 rad/s	0.56 s	40.9 rad/s^2

Linear PPO、NAF 和 SAC 在初始纠偏后将平均轮速提高到 2.0 rad/s 附近，并在约 0.56 秒后进入 ± 0.2 rad/s 的目标带。全程速度 RMSE 约为 1.07 rad/s。该指标包含从静止加速到目标速度的瞬态过程，因此数值高于稳态误差。

表 9 原地平衡任务动态指标

方法	持续时间	最大车身角	最大摆杆角	车身调节时间	摆杆调节时间	轮速 RMS	动作 RMS
Linear PPO	10.00 s	4.21°	2.00°	0.71 s	0.72 s	0.746 rad/s	32.8 rad/s ²
MLP PPO	10.00 s	4.00°	2.00°	0.69 s	0.72 s	0.788 rad/s	33.1 rad/s ²
NAF	10.00 s	4.21°	2.00°	0.71 s	0.72 s	0.746 rad/s	32.8 rad/s ²
SAC	10.00 s	4.20°	2.00°	0.71 s	0.72 s	0.745 rad/s	32.9 rad/s ²

MLP PPO 在前几秒逐渐提高轮速，但动作持续振荡。摆杆角随后快速增大，在 4.32 秒时因 `pole_falling_outward` 终止。其动作 RMS 为 77.8 rad/s²，约为 Linear PPO 的 1.9 倍。该策略为减小速度误差使用了较强控制量，姿态反馈未能及时抑制由此产生的摆杆运动。

4.5 训练与部署开销

表 10 中的运行时间取自训练日志中配置输出至评估结果保存之间的时间差，其中包含热启动、课程评估、策略训练和最终评估。该指标受具体硬件和程序实现影响，只用于本组实验的相对比较。

表 10 训练与部署开销比较

方法	任务	训练步数	日志时间	最终成功率	模型文件大小	导出 actor 参数量
Linear PPO	balance	200k	约 53 s	1.00	20 KB	9
Linear PPO	velocity	200k	约 56 s	1.00	20 KB	9
MLP PPO	balance	600k	约 211 s	0.90	55 KB	833
MLP PPO	velocity	600k	约 161 s	0.00	54 KB	833
NAF	balance	120k	约 232 s	1.00	82 KB	9（仅 actor）
NAF	velocity	120k	约 259 s	1.00	82 KB	9（仅 actor）
SAC	balance	200k	约 333 s	1.00	23 KB	9
SAC	velocity	200k	约 362 s	1.00	23 KB	9

Linear PPO 的训练时间最短，两个任务分别约为 53 秒和 56 秒。其 actor 只有 9 个参数，模型文件约为 20 KB。训练期间各次 hard 评估均保持 100% 成功率，未出现后期性能下降。

MLP PPO 训练 600k 步，actor 参数量为 833。其参数规模仍然适合嵌入式部署，但训练时间和样本量均高于 Linear PPO，最终性能没有相应提高。当前标称模型未体现出增加网络容量的收益。

NAF 和 SAC 可以通过经验回放复用数据，但每一步还包含价值网络、目标网络或温度参数等更新，实际运行时间高于 Linear PPO。两种方法在训练后期还出现当前策略退化，因此较少的环境步数没有转化为更稳定的训练结果。

4.6 动作尺度的影响




图 10 动作尺度对可用控制范围的影响

策略输出为归一化动作，施加到动力学模型上的控制量为

$$u = a u_{\max}.$$

当 $u_{\max}$ 取值过小时，即使 $a = 1$ ，控制器也可能无法在姿态快速发散前完成纠偏。例如 $u_{\max} = 200 \text{ rad/s}^2$ 时，每个 10 ms 控制周期对应的最大轮速变化约为 2 rad/s。当前设置 $u_{\max} = 8000 \text{ rad/s}^2$ 时，该变化量约为 80 rad/s，能够覆盖初始恢复阶段所需的控制强度。

动作尺度需要在训练、评估、可视化和部署环节保持一致。若只在固件侧放大输出，同一个归一化动作将对应训练中未出现过的物理控制量，容易产生过冲。实验统一使用 `action_limit=8000.0`，避免由尺度不一致造成额外误差。

4.7 方法比较小结

在当前线性仿真、固定目标速度和 LQR 热启动条件下，Linear PPO 的最终性能与训练稳定性最均衡。NAF 和 SAC 的最终模型也能完成任务，但训练日志表明强化学习更新没有持续改善初始策略。MLP PPO 的非线性结构在现有环境中增加了优化难度。

表 11 各方法在本实验中的表现概括

方法	实验表现
Linear PPO	两个任务均达到满成功率，课程训练稳定，训练时间和部署开销最低
MLP PPO	原地平衡任务基本可用，但不同检查点波动较大，匀速任务未收敛
NAF	最优检查点达到满成功率，后续当前策略明显退化
SAC	最优检查点达到满成功率，周期评估长期未通过低难度

5 结果讨论

Linear PPO 的表现与实验前对模型结构的判断一致。仿真动力学在直立点附近采用线性模型，LQR 提供线性反馈，Linear PPO 又可以直接继承该反馈权重。初始策略、策略结构和被控模型之间具有较高一致性，PPO 只需在稳定控制器附近进行有限调整。

NAF 和 SAC 的最终评估结果较高，原因需要结合检查点保存机制理解。两种方法在热启动后已经得到可稳定系统的策略，训练程序保存了这一阶段的较优检查点。后续更新使当前策略失稳，最终评估重新加载早期检查点后仍可获得满成功率。由此可见，现有离策略训练没有在 LQR 初始策略基础上形成稳定改进。

MLP PPO 在原地平衡任务中可以处理常见扰动，但高难度评估存在波动。非线性网络的函数容量更大，未充分采样区域的动作输出也更难限制。匀速任务中，目标速度没有进入观测，策略只能针对固定目标形成参数化控制关系。训练数据不足或奖励权重变化时，速度误差和姿态误差之间的平衡容易被破坏。

这些结果适用于当前标称仿真模型。真实小车中存在摩擦、执行器死区、时延和参数误差，线性策略是否仍能保持相同优势，需要通过系统辨识和实车测试验证。现阶段的实验可以确定一套可靠的仿真基线，但不能直接替代实车鲁棒性评估。

6 现有问题及改进方案

6.1 随机探索产生的有效轨迹较少

平衡车从随机策略开始交互时，许多回合会在较少步数内终止。此时经验数据主要由失败状态构成，优势估计和价值估计都难以获得稳定的更新方向。实验通过 LQR 初始化缓解这一问题。Linear PPO 直接写入反馈权重，MLP PPO 使用 LQR 数据进行行为克隆，NAF 和 SAC 也从 LQR 附近开始训练，其中 NAF 还使用教师轨迹预填充经验回放池。

后续实验应增加无 LQR 初始化的对照，以区分初始控制器和强化学习更新各自带来的性能。对离策略方法还可限制早期探索噪声，避免经验回放池很快被短回合失

败数据占据。

6.2 匀速任务缺少目标速度输入

当前 8 维观测只包含系统状态，没有提供目标轮速。固定目标为 2.0 rad/s 时，策略可以在参数中记住这一目标，但无法显式计算速度误差，也不能自然推广到其他目标速度。该问题对 MLP PPO 的影响较为明显。

可将观测扩展为

```
[原 8 维状态, target_wheel_velocity]
```

也可以直接加入

```
wheel_rate - target_wheel_velocity
```

随后在多个目标速度下混合训练，检查策略是否能够根据目标变化调整控制动作。

6.3 离策略更新偏离初始稳定控制器

NAF 和 SAC 的周期评估显示，actor 在后续训练中逐渐离开 LQR 附近的稳定区域。critic 估计误差、探索噪声和经验分布变化都可能造成这一现象。当前使用最优检查点恢复可以保留较好模型，但没有解决训练过程本身的退化。

一种可行方案是采用残差控制

$$u(s) = u_{\text{LQR}}(s) + \Delta u_{\theta}(s),$$

并限制 $\Delta u_{\theta}(s)$ 的幅值。策略只学习对 LQR 的小幅修正，失稳风险低于直接输出完整控制量。还可以加入行为克隆约束或策略距离约束，使 actor 更新不会在少量批次后偏离初始反馈过远。

6.4 动作尺度与固件接口需要统一

动作上限决定归一化动作对应的实际控制强度。训练和固件使用不同尺度时，仿真结果无法直接反映实车响应。实车测试前需要核对动作单位、正负方向、状态排列、采样周期和底层速度环响应。建议先进行悬空测试，确认策略输出到电机指令的映射正确，再逐步增加落地测试时间和允许姿态范围。

6.5 仿真模型对真实系统的覆盖有限

当前环境采用标称线性模型，未完整描述摩擦、电机死区、PWM 饱和、传感器噪声、控制延迟、电池电压变化和装配误差。这些因素会改变稳定范围，也可能使非线性策

略在实车上体现出优势。

后续可采集真实小车的状态与控制数据，重新估计模型参数。在训练环境中加入质量、长度、摩擦和时延随机化，并在不同扰动强度下评估策略。仿真参数的变化范围应依据实测数据确定，避免使用缺乏物理依据的过大随机扰动。

7 后续实验安排

1. **LQR 初始化消融。**比较随机初始化、仅使用 LQR、LQR 初始化后继续强化学习三种设置，记录最终成功率和完整训练曲线。
2. **目标速度条件化。**将目标轮速或速度误差加入观测，在 0、1、2 和 3 rad/s 等多个目标下联合训练。
3. **残差离策略控制。**分别测试原始 SAC、残差 SAC 以及带行为约束的残差 SAC，重点观察当前策略是否仍在训练后期退化。
4. **增加 TD3 对照。**使用双 critic 和延迟 actor 更新，检查其是否能减轻价值高估及 actor 失稳。
5. **动力学随机化。**在有实测依据的范围内改变质量、长度、摩擦、噪声和控制延迟，比较标称环境与扰动环境中的成功率。
6. **实车闭环记录。**同步记录状态、策略动作、目标轮速、实际轮速和 PWM 输出，用于检查执行链误差并修正仿真模型。

8 结论

本文在统一的二阶平衡车仿真环境中比较了 Linear PPO、MLP PPO、NAF 和 SAC。Linear PPO 在原地平衡和匀速跟踪任务中均达到 hard 难度的 100% 成功率，课程训练过程稳定，训练时间最短，导出 actor 仅包含 9 个参数。基于当前实验设置，该方法具有最好的综合表现。

NAF 和 SAC 保存的最优检查点同样完成了两个任务，但当前策略在后续离策略更新中明显退化。MLP PPO 可以完成多数原地平衡回合，在匀速任务中则出现持续振荡和摆杆失稳。实验结果表明，现有线性仿真中，增加网络容量没有改善控制效果，训练稳定性反而下降。

后续实车验证可先采用 Linear PPO 作为基线，并重点检查动作尺度、状态顺序和底层执行接口。在此基础上，再通过系统辨识、目标速度条件化、残差控制和动力学随机化提高对真实系统误差的适应能力。